

Dirichlet Prior Networks

Synthèse mathématique de l'article *Reverse KL-Divergence Training of Prior Networks: Improved Uncertainty and Adversarial Robustness*,
NeurIPS 2019.

A. P.

15 mai 2026

Table des matières

1	La distribution de Dirichlet	2
1.1	Le simplexe ouvert	2
1.2	Définition de la loi de Dirichlet	3
1.3	Rappel sur la loi Gamma	4
1.4	Normalisation de la loi de Dirichlet : l'intégrale de Dirichlet	4
1.5	Propriétés	5
2	Divergence de Kullback–Leibler	7
2.1	Continuité absolue et dérivée de Radon–Nikodym	7
2.2	Définition de la divergence de Kullback–Leibler	7
2.3	Propriétés fondamentales	8
2.4	Entropie et entropie croisée	9
2.5	La fonction digamma et l'espérance de $\log \pi_c$	9
2.6	Formule explicite de la divergence KL entre deux distributions de Dirichlet .	10
2.7	Mélanges arithmétique et géométrique de lois	10
3	Dirichlet Prior Networks	11
3.1	Définition et architecture	11
3.2	Le problème d'apprentissage	12
3.3	Distributions cibles par classe	12
3.4	Critère forward et cible induite	13
3.5	Critère reverse et cible induite	13
3.6	Thèse de l'article	14
3.7	Conclusion	14
4	ANNEXE : Objets et Théorèmes utilisés	15
4.1	Espace mesuré et intégrale de Lebesgue	15
4.2	La mesure de Lebesgue sur $\mathbb{R}$ et les intégrales de référence	16
4.3	Optimisation sous contraintes	17

Introduction

Ce document est une synthèse mathématique de l'article de Malinin et Gales, *Reverse KL-Divergence Training of Prior Networks: Improved Uncertainty and Adversarial Robustness*, NeurIPS 2019 [2]. Les Prior Networks, introduits par Malinin et Gales en 2018, sont des réseaux de neurones classifieurs qui prédisent une distribution sur l'ensemble des distributions possibles, permettant de séparer l'incertitude due au bruit des données de celle due au manque de connaissance du modèle. Le présent article (NeurIPS 2019) identifie un défaut fondamental dans le critère d'entraînement proposé dans ce travail original : avec la divergence KL directe, le modèle apprend un comportement pathologique en présence d'ambiguïté, produisant des distributions mal calibrées. Les auteurs proposent d'utiliser la divergence KL inverse à la place, et montrent que ce nouveau critère corrige le problème et permet d'entraîner des Prior Networks sur des tâches plus complexes. De plus les résultats sur CIFAR-10 et CIFAR-100 montrent qu'il est significativement plus difficile de construire des attaques adaptatives efficaces contre ces modèles que contre les défenses standard.

L'idée est d'explicitier et de démontrer les fondements mathématiques de la thèse de cet article. Plusieurs affirmations présentées sans preuve ou dont la justification est implicite sont redéfinies ici et démontrées, notamment la définition et la normalisation de la loi de Dirichlet, le calcul explicite de la divergence de Kullback–Leibler entre deux lois de Dirichlet, et la propriété centrale selon laquelle le critère d'entraînement *reverse* induit en espérance une unique loi de Dirichlet unimodale, là où le critère *forward* induit un mélange arithmétique en général multimodal.

1 La distribution de Dirichlet

On fixe un entier $K \geq 2$.

1.1 Le simplexe ouvert

Définition 1.1. Le *simplexe ouvert* de dimension $K - 1$ est

$$\Delta_{K-1}^\circ := \left\{ \pi = (\pi_1, \dots, \pi_K) \in (\mathbb{R}_+^*)^K : \sum_{c=1}^K \pi_c = 1 \right\}.$$

Le simplexe Δ_{K-1}° , vu comme partie de $\mathbb{R}^K$, est inclus dans un hyperplan affine de dimension $K - 1$; il est de mesure de Lebesgue nulle pour λ_K . Intégrer directement sur Δ_{K-1}° relativement à λ_K ne ferait sens que si le simplexe avait une épaisseur dans $\mathbb{R}^K$, ce qui n'est pas le cas. L'idée est de paramétrer le simplexe par un ouvert de $\mathbb{R}^{K-1}$ via une bijection explicite φ , puis de définir une mesure sur Δ_{K-1}° comme l'image de la mesure de Lebesgue λ_{K-1} par cette bijection. Intégrer une fonction g sur Δ_{K-1}° revient alors à intégrer $g \circ \varphi$ sur un ouvert ordinaire de $\mathbb{R}^{K-1}$.

Définition 1.2 (Paramétrisation canonique et mesure de référence). On note

$$T := \left\{ (\pi_1, \dots, \pi_{K-1}) \in (\mathbb{R}_+^*)^{K-1} : \sum_{c=1}^{K-1} \pi_c < 1 \right\} \subset \mathbb{R}^{K-1},$$

et on définit la *paramétrisation canonique*

$$\varphi : T \longrightarrow \Delta_{K-1}^\circ, \quad (\pi_1, \dots, \pi_{K-1}) \mapsto \left(\pi_1, \dots, \pi_{K-1}, 1 - \sum_{c=1}^{K-1} \pi_c \right).$$

L'application φ est un homéomorphisme de T sur Δ_{K-1}° .

On définit la *mesure de référence* sur Δ_{K-1}° comme la mesure image

$$\lambda_\Delta := \varphi_*(\lambda_{K-1}|_T),$$

où $\lambda_{K-1}|_T$ désigne la restriction de la mesure de Lebesgue sur $\mathbb{R}^{K-1}$ à l'ouvert T .

Donc pour toute fonction $g : \Delta_{K-1}^\circ \rightarrow \mathbb{R}_+$ mesurable,

$$\int_{\Delta_{K-1}^\circ} g d\lambda_\Delta = \int_T g(\varphi(\pi_1, \dots, \pi_{K-1})) d\lambda_{K-1}(\pi_1, \dots, \pi_{K-1}).$$

1.2 Définition de la loi de Dirichlet

Définition 1.3. Soit $\alpha = (\alpha_1, \dots, \alpha_K) \in (\mathbb{R}_+^*)^K$. On pose

$$\alpha_0 := \sum_{c=1}^K \alpha_c, \quad B(\alpha) := \frac{\prod_{c=1}^K \Gamma(\alpha_c)}{\Gamma(\alpha_0)}.$$

La *loi de Dirichlet* $\text{Dir}(\alpha)$ est la mesure de probabilité sur Δ_{K-1}° de densité (par rapport à λ_Δ)

$$p(\pi \mid \alpha) := \frac{1}{B(\alpha)} \prod_{c=1}^K \pi_c^{\alpha_c-1}, \quad \pi \in \Delta_{K-1}^\circ.$$

Le scalaire α_0 est appelé *précision* de la loi. Dans tout ce qui suit, on emploie librement les trois expressions équivalentes : loi de Dirichlet, distribution de Dirichlet et mesure de Dirichlet selon le contexte.




Figure 1: Loi de Dirichlet $\text{Dir}(\alpha)$ sur le simplexe Δ_2° (bleu foncé = forte densité, blanc = densité nulle) pour $\alpha = (15, 1, 1)$, $\alpha = (7, 7, 7)$, et $\alpha = (0.35, 0.35, 0.35)$

Remarque 1.4. Pour que cette définition soit cohérente il faut vérifier que la fonction $p(\cdot \mid \alpha)$ est bien intégrable sur Δ_{K-1}° et que son intégrale vaut 1, ce qui revient à établir

$$\int_{\Delta_{K-1}^\circ} \prod_{c=1}^K \pi_c^{\alpha_c-1} d\lambda_\Delta = B(\alpha).$$

C'est l'objet du Théorème 1.7.

1.3 Rappel sur la loi Gamma

Définition 1.5. Pour $\alpha > 0$, la loi *Gamma* $\text{Gamma}(\alpha)$ est la mesure de probabilité sur $\mathbb{R}_+^*$ de densité (par rapport à λ)

$$g_\alpha(t) := \frac{t^{\alpha-1} e^{-t}}{\Gamma(\alpha)}, \quad t > 0.$$

Son intégrabilité et sa normalisation viennent de la Proposition 1.9.

1.4 Normalisation de la loi de Dirichlet : l'intégrale de Dirichlet

On démontre la normalisation par récurrence sur K , en s'appuyant sur la fonction Bêta ($K = 2$) et en réduisant le cas général par une intégration itérée avec le Théorème de Fubini–Tonelli.

Proposition 1.6 (Fonction Bêta). *Pour tous $a, b > 0$, la fonction Bêta est définie par*

$$B(a, b) := \int_0^1 t^{a-1} (1-t)^{b-1} d\lambda(t),$$

et vérifie

$$B(a, b) = \frac{\Gamma(a) \Gamma(b)}{\Gamma(a+b)}.$$

Démonstration. On calcule le produit $\Gamma(a)\Gamma(b)$ comme double intégrale sur $(\mathbb{R}_+^*)^2$:

$$\Gamma(a) \Gamma(b) = \int_0^\infty u^{a-1} e^{-u} d\lambda(u) \cdot \int_0^\infty v^{b-1} e^{-v} d\lambda(v) = \int_{(\mathbb{R}_+^*)^2} u^{a-1} v^{b-1} e^{-(u+v)} d\lambda_2(u, v),$$

la deuxième égalité découlant de Fubini–Tonelli. On effectue le changement de variables $u = ts$, $v = (1-t)s$ (avec $s > 0$, $t \in]0, 1[$), de jacobien $J = s$. Alors $u + v = s$, et par une nouvelle application de Fubini–Tonelli :

$$\begin{aligned} \Gamma(a) \Gamma(b) &= \int_0^\infty \int_0^1 (ts)^{a-1} ((1-t)s)^{b-1} e^{-s} \cdot s d\lambda(t) d\lambda(s) \\ &= \left(\int_0^1 t^{a-1} (1-t)^{b-1} d\lambda(t) \right) \cdot \left(\int_0^\infty s^{a+b-1} e^{-s} d\lambda(s) \right) = B(a, b) \cdot \Gamma(a+b), \end{aligned}$$

d'où le résultat. □

Théorème 1.7 (Intégrale de Dirichlet). *Pour tout $K \geq 2$ et tout $\alpha = (\alpha_1, \dots, \alpha_K) \in (\mathbb{R}_+^*)^K$,*

$$\int_{\Delta_{K-1}^\circ} \prod_{c=1}^K \pi_c^{\alpha_c-1} d\lambda_\Delta(\pi) = B(\alpha) = \frac{\prod_{c=1}^K \Gamma(\alpha_c)}{\Gamma(\alpha_0)}.$$

En particulier, $p(\cdot | \alpha)$ est une densité de probabilité sur Δ_{K-1}° .

Démonstration. On procède par récurrence sur $K \geq 2$.

Initialisation ($K = 2$). Le simplexe $\Delta_1^\circ = \{(\pi_1, 1 - \pi_1) : \pi_1 \in]0, 1[\}$ est paramétré par $\varphi : t \mapsto (t, 1 - t)$ sur $T =]0, 1[$, et λ_Δ coïncide avec la mesure de Lebesgue sur $]0, 1[$. L'intégrale s'écrit donc

$$\int_{\Delta_1^\circ} \pi_1^{\alpha_1-1} \pi_2^{\alpha_2-1} d\lambda_\Delta = \int_0^1 t^{\alpha_1-1} (1-t)^{\alpha_2-1} d\lambda(t) = B(\alpha_1, \alpha_2) = \frac{\Gamma(\alpha_1) \Gamma(\alpha_2)}{\Gamma(\alpha_0)},$$

ce qui est bien $B(\alpha)$.

Hérédité. Supposons le résultat établi au rang $K - 1$ (pour tout vecteur de paramètres dans $(\mathbb{R}_+^*)^{K-1}$), et montrons-le au rang K . On utilise la paramétrisation $\varphi : T \rightarrow \Delta_{K-1}^\circ$ définie en section 2. En posant $\pi_K = 1 - \sum_{c=1}^{K-1} \pi_c$ et en notant $\pi' = (\pi_1, \dots, \pi_{K-1})$, l'intégrale s'écrit :

$$I_K(\alpha) := \int_T \prod_{c=1}^{K-1} \pi_c^{\alpha_c-1} \cdot \left(1 - \sum_{c=1}^{K-1} \pi_c\right)^{\alpha_K-1} d\lambda_{K-1}(\pi').$$

On pose $s := \sum_{c=1}^{K-1} \pi_c \in]0, 1[$. Pour s fixé, le vecteur $(\pi_1/s, \dots, \pi_{K-1}/s)$ parcourt le simplexe Δ_{K-2}° . On effectue le changement de variables $\pi_c = s\rho_c$ (pour $c = 1, \dots, K-2$) et $\pi_{K-1} = s - \sum_{c=1}^{K-2} s\rho_c$, le jacobien valant s^{K-2} . D'où, par Fubini-Tonelli :

$$I_K(\alpha) = \int_0^1 s^{\alpha'_0-1} (1-s)^{\alpha_K-1} d\lambda(s) \cdot \int_{\Delta_{K-2}^\circ} \prod_{c=1}^{K-1} \rho_c^{\alpha_c-1} d\lambda_{\Delta'}(\rho),$$

où $\alpha'_0 = \sum_{c=1}^{K-1} \alpha_c = \alpha_0 - \alpha_K$ et $\rho_{K-1} = 1 - \sum_{c=1}^{K-2} \rho_c$. La première intégrale vaut $B(\alpha'_0, \alpha_K) = \Gamma(\alpha'_0)\Gamma(\alpha_K)/\Gamma(\alpha_0)$. La seconde intégrale vaut $\prod_{c=1}^{K-1} \Gamma(\alpha_c)/\Gamma(\alpha'_0)$ par hypothèse de récurrence au rang $K-1$. En multipliant :

$$I_K(\alpha) = \frac{\Gamma(\alpha'_0)\Gamma(\alpha_K)}{\Gamma(\alpha_0)} \cdot \frac{\prod_{c=1}^{K-1} \Gamma(\alpha_c)}{\Gamma(\alpha'_0)} = \frac{\prod_{c=1}^K \Gamma(\alpha_c)}{\Gamma(\alpha_0)} = B(\alpha). \quad \square$$

1.5 Propriétés

Proposition 1.8. *Soit $\pi \sim \text{Dir}(\alpha)$. Pour tout $c \in \{1, \dots, K\}$,*

$$\mathbb{E}[\pi_c] = \frac{\alpha_c}{\alpha_0}.$$

Démonstration. On observe que $\pi_c \cdot \prod_{j=1}^K \pi_j^{\alpha_j-1} = \prod_{j=1}^K \pi_j^{(\alpha_j+\delta_{jc})-1}$, où δ_{jc} est le symbole de Kronecker. Notons e_c le c -ème vecteur de la base canonique de $\mathbb{R}^K$. Alors, par définition de l'intégrale par rapport à λ_Δ :

$$\mathbb{E}[\pi_c] = \int_{\Delta_{K-1}^\circ} \pi_c \cdot p(\pi \mid \alpha) d\lambda_\Delta(\pi) = \frac{1}{B(\alpha)} \int_{\Delta_{K-1}^\circ} \prod_{j=1}^K \pi_j^{(\alpha_j+\delta_{jc})-1} d\lambda_\Delta(\pi).$$

En appliquant le Théorème 1.7 au vecteur de paramètres $\alpha + e_c$ (dont toutes les composantes sont encore dans $\mathbb{R}_+^*$), on obtient

$$\int_{\Delta_{K-1}^\circ} \prod_{j=1}^K \pi_j^{(\alpha_j+\delta_{jc})-1} d\lambda_\Delta(\pi) = B(\alpha + e_c) = \frac{\Gamma(\alpha_c + 1) \prod_{j \neq c} \Gamma(\alpha_j)}{\Gamma(\alpha_0 + 1)}.$$

On utilise la relation fonctionnelle $\Gamma(s+1) = s\Gamma(s)$ pour simplifier :

$$\frac{B(\alpha + e_c)}{B(\alpha)} = \frac{\Gamma(\alpha_c + 1)/\Gamma(\alpha_0 + 1)}{\Gamma(\alpha_c)/\Gamma(\alpha_0)} = \frac{\alpha_c}{\alpha_0}.$$

On conclut que $\mathbb{E}[\pi_c] = B(\alpha + e_c)/B(\alpha) = \alpha_c/\alpha_0$. $\square$

Remarque 1.9. Le vecteur $(\alpha_1/\alpha_0, \dots, \alpha_K/\alpha_0)$ est la *moyenne* de la distribution de Dirichlet : c'est le barycentre du simplexe pondéré par les paramètres de concentration. La précision α_0 contrôle la concentration autour de cette moyenne : plus α_0 est grand, plus la distribution est piquée. Le cas $\alpha = (1, \dots, 1)$ ($\alpha_0 = K$) correspond à la distribution uniforme sur Δ_{K-1}° .

Définition 1.10 (Unimodalité). Soit μ une mesure de probabilité sur Δ_{K-1}° admettant une densité p continue par rapport à λ_Δ . On dit que μ est *unimodale* s'il existe un unique point $\pi^* \in \Delta_{K-1}^\circ$ tel que

$$p(\pi^*) = \sup_{\pi \in \Delta_{K-1}^\circ} p(\pi).$$

Ce point est appelé le *mode* de μ . Si ce point n'est pas unique on dit que μ est *multimodale*.

Proposition 1.11 (Unimodalité de la loi de Dirichlet). Soit $\alpha \in (\mathbb{R}_+^*)^K$ avec $\alpha_c \geq 1$ pour tout c . Alors la loi $\text{Dir}(\alpha)$ est unimodale sur Δ_{K-1}° , de mode

$$\pi^* = \left(\frac{\alpha_c - 1}{\alpha_0 - K} \right)_{c=1}^K.$$

Démonstration. La densité $p(\pi \mid \alpha) = B(\alpha)^{-1} \prod_{c=1}^K \pi_c^{\alpha_c - 1}$ est strictement positive sur Δ_{K-1}° . On utilise son logarithme,

$$\log p(\pi \mid \alpha) = -\log B(\alpha) + \sum_{c=1}^K (\alpha_c - 1) \log \pi_c,$$

qui a les mêmes points critiques. Montrons que cette fonction est strictement concave sur Δ_{K-1}° , ce qui implique l'unicité d'un maximum global.

Concavité. La fonction $t \mapsto \log t$ est strictement concave sur $\mathbb{R}_+^*$, donc $\pi \mapsto (\alpha_c - 1) \log \pi_c$ est concave pour $\alpha_c \geq 1$ (coefficient positif ou nul). Une somme de fonctions concaves est concave ; comme au moins un $\alpha_c > 1$ (car $\alpha_0 = \sum_c \alpha_c \geq K$ et les α_c ne sont pas tous égaux à 1 en général), la somme est même strictement concave. Ainsi $\log p(\cdot \mid \alpha)$ est strictement concave sur le convexe Δ_{K-1}° , et $p(\cdot \mid \alpha)$ est log-concave, donc unimodale.

Calcul du mode.

On maximise $\sum_c (\alpha_c - 1) \log \pi_c$ sous la contrainte $\sum_c \pi_c = 1$ avec $\pi_c > 0$. Par le Théorème 4.10 appliqué à $F(\pi) = \sum_c (\alpha_c - 1) \log \pi_c$ et $g(\pi) = \sum_c \pi_c - 1$ (on a $\nabla g = (1, \dots, 1) \neq 0$, et la suffisance est assurée par la stricte concavité de F), il existe un multiplicateur $\lambda \in \mathbb{R}$ tel que $\nabla F(\pi^*) = \lambda \nabla g(\pi^*)$, soit :

$$\frac{\alpha_c - 1}{\pi_c} = \lambda \quad \forall c,$$

soit $\pi_c = (\alpha_c - 1)/\lambda$. La contrainte $\sum_c \pi_c = 1$ impose $\lambda = \sum_c (\alpha_c - 1) = \alpha_0 - K$, qui est strictement positif car $\alpha_c \geq 1$ pour tout c et $\alpha_0 > K$ dès qu'un $\alpha_c > 1$. On obtient $\pi_c^* = (\alpha_c - 1)/(\alpha_0 - K)$. $\square$

Remarque 1.12. Lorsque $\alpha_c = 1$ pour tout c (distribution uniforme sur Δ_{K-1}°), la densité est constante et tout point est un mode : le résultat s'applique de façon dégénérée. La condition $\alpha_c \geq 1$ est nécessaire : pour $\alpha_c < 1$, la densité diverge vers $+\infty$ au coin c du simplexe et la distribution est multimodale.

2 Divergence de Kullback–Leibler

Cette section rassemble les objets et résultats de théorie de l'information nécessaires à l'analyse des fonctions de perte des Prior Networks (partie 4). On définit la divergence de Kullback–Leibler, on en établit les propriétés fondamentales, on calcule sa forme explicite entre deux lois de Dirichlet, et on introduit les notions de mélange arithmétique et géométrique qui distingueront les comportements des critères forward et reverse.

2.1 Continuité absolue et dérivée de Radon–Nikodym

Définition 2.1. Soient μ, ν deux mesures sur $(X, \mathcal{B})$. On dit que ν est *absolument continue* par rapport à μ , et on note $\nu \ll \mu$, si pour tout $A \in \mathcal{B}$,

$$\mu(A) = 0 \implies \nu(A) = 0.$$

Théorème 2.2 (Radon–Nikodym, Remarque 3.3.4 de [1]). Soient μ, ν deux mesures σ -finies sur $(X, \mathcal{B})$ avec $\nu \ll \mu$. Alors il existe une fonction $w \in \mathcal{M}_+(X)$, unique à égalité μ -presque partout près, telle que pour tout $A \in \mathcal{B}$,

$$\nu(A) = \int_A w \, d\mu.$$

La fonction w est appelée dérivée de Radon–Nikodym de ν par rapport à μ et notée $\frac{d\nu}{d\mu}$.

Remarque 2.3. Lorsque $\mu = \lambda_n$ est la mesure de Lebesgue et que ν admet une densité f au sens usuel, alors $d\nu/d\mu = f$ presque partout. La dérivée de Radon–Nikodym généralise donc la notion de densité à une mesure de référence arbitraire.

2.2 Définition de la divergence de Kullback–Leibler

Définition 2.4. Soient P, Q deux mesures de probabilité sur $(X, \mathcal{B})$. La *divergence de Kullback–Leibler* de P vers Q est

$$\text{KL}(P\|Q) := \begin{cases} \int_X \log \frac{dP}{dQ} \, dP & \text{si } P \ll Q, \\ +\infty & \text{sinon.} \end{cases}$$

Remarque 2.5. Lorsque P et Q admettent des densités p et q par rapport à une même mesure de référence μ (et que $\{q = 0\} \subseteq \{p = 0\}$ à un ensemble μ -négligeable près), la formule se réécrit sous la forme

$$\text{KL}(P\|Q) = \int_X p \log \frac{p}{q} \, d\mu.$$

C'est sous cette forme qu'on calculera la divergence KL entre deux distributions de Dirichlet, avec $\mu = \lambda_\Delta$.

Jusqu'ici l'intégrale de Riemann aurait suffi : l'intégrale de Dirichlet et le calcul de $\mathbb{E}[\pi_c]$ ne font intervenir que des intégrales de fonctions faiblement singulières sur un domaine borné. La divergence de Kullback–Leibler se définit entre deux mesures de probabilité quelconques avec la dérivée de Radon–Nikodym dP/dQ qui n'existe que dans le cadre de la théorie de la mesure.

2.3 Propriétés fondamentales

Proposition 2.6 (Positivité, inégalité de Gibbs). *Pour toutes mesures de probabilité P, Q , on a $\text{KL}(P\|Q) \geq 0$, avec égalité si et seulement si $P = Q$.*

Démonstration. Si $P \not\ll Q$, l'inégalité est triviale. Supposons $P \ll Q$ et posons $r = dP/dQ$. La fonction $\varphi : t \mapsto t \log t$ (prolongée par 0 en 0) est convexe sur $\mathbb{R}_+$. Comme $\int_X r dQ = \int_X dP = 1$, l'inégalité de Jensen appliquée à φ et à la mesure de probabilité Q donne

$$\text{KL}(P\|Q) = \int_X r \log r dQ = \int_X \varphi(r) dQ \geq \varphi\left(\int_X r dQ\right) = \varphi(1) = 0.$$

Comme φ est strictement convexe, l'égalité dans Jensen impose r constante Q -presque partout ; jointe à $\int r dQ = 1$, cela force $r = 1$ Q -presque partout, c'est-à-dire $P = Q$. $\square$

Remarque 2.7 (Asymétrie). En général $\text{KL}(P\|Q) \neq \text{KL}(Q\|P)$: la divergence KL n'est pas une distance. Cette asymétrie a une interprétation géométrique. Soit une cible P fixée et un modèle Q_θ que l'on ajuste en minimisant la divergence KL.

- Minimiser $\text{KL}(P\|Q_\theta)$ (*KL forward*) pénalise fortement les régions où $P > 0$ mais $Q_\theta \approx 0$: le modèle est contraint de couvrir tous les modes de P , quitte à étaler de la masse là où P est faible.
- Minimiser $\text{KL}(Q_\theta\|P)$ (*KL reverse*) pénalise les régions où $Q_\theta > 0$ mais $P \approx 0$: le modèle se concentre sur un seul mode de P et ignore les autres.




Figure 2: Illustration de l'asymétrie sur le simplexe Δ_2^o pour un modèle Q_θ contraint à être une loi de Dirichlet unimodale. (*Gauche*) Cible P : mélange arithmétique $\frac{1}{2}\text{Dir}(\beta^{(1)}) + \frac{1}{2}\text{Dir}(\beta^{(2)})$, bimodale avec un pic au coin bas-gauche et un au coin bas-droit. (*Centre*) Minimisation de $\text{KL}(P\|Q_\theta)$: le modèle est pénalisé dès qu'il affecte une masse nulle là où $P > 0$, ce qui le force à étaler sa masse le long de la base du simplexe pour couvrir les deux modes au prix d'une forte densité dans des régions de faible probabilité cible. (*Droite*) Minimisation de $\text{KL}(Q_\theta\|P)$: le modèle est pénalisé dès qu'il place de la masse là où $P \approx 0$, ce qui le force à se concentrer sur un seul coin du simplexe en ignorant l'autre.

La conséquence précise pour les Prior Networks (cible multi-modale non représentable par un modèle unimodal) est exploitée en partie 4.

2.4 Entropie et entropie croisée

Définition 2.8. Soit μ une mesure de référence et P, Q deux mesures de probabilité de densités p, q par rapport à μ . L'entropie (différentielle) de P et l'entropie croisée de P relativement à Q sont

$$H(P) := - \int_X p \log p d\mu, \quad H(P, Q) := - \int_X p \log q d\mu.$$

Proposition 2.9. Avec les notations précédentes, $\text{KL}(P\|Q) = H(P, Q) - H(P)$.

Démonstration. Immédiat : $\text{KL}(P\|Q) = \int p \log(p/q) d\mu = \int p \log p d\mu - \int p \log q d\mu = -H(P) + H(P, Q)$. $\square$

Remarque 2.10. L'entropie différentielle dépend du choix de la mesure de référence μ , contrairement à la divergence KL qui en est indépendante. Cela ne pose pas de problème dans la suite car seules des différences de la forme $H(P, Q) - H(P)$ interviennent dans les fonctions de perte.

2.5 La fonction digamma et l'espérance de $\log \pi_c$

Définition 2.11. La fonction digamma est la dérivée logarithmique de la fonction Gamma :

$$\psi(s) := \frac{d}{ds} \log \Gamma(s) = \frac{\Gamma'(s)}{\Gamma(s)}, \quad s > 0.$$

Proposition 2.12. Soit $\pi \sim \text{Dir}(\alpha)$. Pour tout $c \in \{1, \dots, K\}$,

$$\mathbb{E}[\log \pi_c] = \psi(\alpha_c) - \psi(\alpha_0).$$

Démonstration. Partons de l'identité de normalisation (Théorème 1.7), valable pour tout $\alpha \in (\mathbb{R}_+^*)^K$:

$$\int_{\Delta_{K-1}^\circ} \prod_{j=1}^K \pi_j^{\alpha_j-1} d\lambda_\Delta = B(\alpha).$$

Dérivons les deux membres par rapport à α_c . L'interversion de la dérivation et de l'intégrale est licite par le Théorème 4.7 : pour α_c dans un compact $I \subset \mathbb{R}_+^*$, la dérivée partielle vaut $\partial_{\alpha_c} \pi_j^{\alpha_j-1} = \delta_{jc} \pi_c^{\alpha_c-1} \log \pi_c$, et la fonction $\pi \mapsto \pi_c^{\alpha_c-1} |\log \pi_c|$ est bornée sur Δ_{K-1}° uniformément en $\alpha_c \in I$ (la singularité en $\pi_c = 0$ est intégrable car $\pi_c^{\alpha_c-1} |\log \pi_c| \rightarrow 0$ quand $\pi_c \rightarrow 0^+$ pour $\alpha_c > 0$). Le membre de gauche donne, puisque $\partial_{\alpha_c} \pi_j^{\alpha_j-1} = \delta_{jc} \pi_c^{\alpha_c-1} \log \pi_c$:

$$\int_{\Delta_{K-1}^\circ} \log \pi_c \prod_{j=1}^K \pi_j^{\alpha_j-1} d\lambda_\Delta = B(\alpha) \mathbb{E}[\log \pi_c].$$

Pour le membre de droite, on écrit $\log B(\alpha) = \sum_j \log \Gamma(\alpha_j) - \log \Gamma(\alpha_0)$ avec $\alpha_0 = \sum_j \alpha_j$, donc $\partial_{\alpha_c} \log B(\alpha) = \psi(\alpha_c) - \psi(\alpha_0)$, d'où

$$\partial_{\alpha_c} B(\alpha) = B(\alpha) (\psi(\alpha_c) - \psi(\alpha_0)).$$

En égalant les deux expressions et en divisant par $B(\alpha) > 0$, on obtient le résultat. $\square$

2.6 Formule explicite de la divergene KL entre deux distributions de Dirichlet

Proposition 2.13. *Pour tous $\alpha, \beta \in (\mathbb{R}_+^*)^K$,*

$$\text{KL}(\text{Dir}(\alpha) \parallel \text{Dir}(\beta)) = \log \frac{B(\beta)}{B(\alpha)} + \sum_{c=1}^K (\alpha_c - \beta_c) (\psi(\alpha_c) - \psi(\alpha_0)).$$

Démonstration. Les deux lois admettent une densité strictement positive sur Δ_{K-1}° par rapport à λ_Δ , donc $\text{Dir}(\alpha) \ll \text{Dir}(\beta)$. Par définition,

$$\begin{aligned} \text{KL}(\text{Dir}(\alpha) \parallel \text{Dir}(\beta)) &= \mathbb{E}_{\pi \sim \text{Dir}(\alpha)} \left[\log \frac{p(\pi \mid \alpha)}{p(\pi \mid \beta)} \right] \\ &= \mathbb{E}_{\pi \sim \text{Dir}(\alpha)} \left[\log \frac{B(\beta)}{B(\alpha)} + \sum_{c=1}^K (\alpha_c - \beta_c) \log \pi_c \right] \\ &= \log \frac{B(\beta)}{B(\alpha)} + \sum_{c=1}^K (\alpha_c - \beta_c) \mathbb{E}_{\pi \sim \text{Dir}(\alpha)} [\log \pi_c]. \end{aligned}$$

On conclut par la Proposition 3.12. □

2.7 Mélanges arithmétique et géométrique de lois

On fixe des poids $w_1, \dots, w_K \geq 0$ vérifiant $\sum_{c=1}^K w_c = 1$, et des mesures de probabilité $P_1, \dots, P_K$ de densités $p_1, \dots, p_K$ par rapport à une référence μ .

Définition 2.14. Le *mélange arithmétique* des P_c de poids (w_c) est la mesure de probabilité de densité $\sum_{c=1}^K w_c p_c$. Le *mélange géométrique* des P_c de poids (w_c) est la mesure de probabilité de densité

$$\frac{1}{Z} \prod_{c=1}^K p_c^{w_c}, \quad Z := \int_X \prod_{c=1}^K p_c^{w_c} d\mu,$$

lorsque la constante de normalisation Z est finie et strictement positive.

Proposition 2.15 (Le mélange géométrique de Dirichlets est une Dirichlet). *Soient $\beta^{(1)}, \dots, \beta^{(K)} \in (\mathbb{R}_+^*)^K$ et des poids $w_c \geq 0$ avec $\sum_c w_c = 1$. Le mélange géométrique des lois $\text{Dir}(\beta^{(c)})$ de poids (w_c) est exactement la loi $\text{Dir}(\bar{\beta})$, où*

$$\bar{\beta} := \sum_{c=1}^K w_c \beta^{(c)}$$

est le mélange arithmétique des vecteurs de concentration.

Démonstration. Notons $p_c(\pi) = p(\pi \mid \beta^{(c)}) = B(\beta^{(c)})^{-1} \prod_k \pi_k^{\beta_k^{(c)} - 1}$. En élevant à la puissance w_c et en faisant le produit sur c :

$$\prod_{c=1}^K p_c(\pi)^{w_c} = \underbrace{\left(\prod_{c=1}^K B(\beta^{(c)})^{-w_c} \right)}_{\text{constante en } \pi} \cdot \prod_{k=1}^K \pi_k^{\sum_c w_c (\beta_k^{(c)} - 1)}.$$

Or, comme $\sum_c w_c = 1$, l'exposant de π_k vaut

$$\sum_{c=1}^K w_c \left(\beta_k^{(c)} - 1 \right) = \sum_{c=1}^K w_c \beta_k^{(c)} - 1 = \bar{\beta}_k - 1.$$

Ainsi $\prod_c p_c^{w_c}$ est proportionnel (à une constante multiplicative près, indépendante de π) à $\prod_k \pi_k^{\bar{\beta}_k - 1}$. Comme $\bar{\beta} \in (\mathbb{R}_+^*)^K$ (combinaison convexe de vecteurs à coordonnées strictement positives), le Théorème 1.7 garantit que $\int_{\Delta_{K-1}^\circ} \prod_k \pi_k^{\bar{\beta}_k - 1} d\lambda_\Delta = B(\bar{\beta}) < \infty$. La constante de normalisation Z du mélange géométrique est donc finie et strictement positive, et la densité normalisée est

$$\frac{1}{B(\bar{\beta})} \prod_{k=1}^K \pi_k^{\bar{\beta}_k - 1} = p(\pi \mid \bar{\beta}),$$

c'est-à-dire la densité de $\text{Dir}(\bar{\beta})$. □

Remarque 2.16. C'est cette proposition qui explique pourquoi le critère reverse induit une cible unimodale : la combinaison qui apparaît dans son espérance est un mélange géométrique de lois de Dirichlets, donc une unique loi de Dirichlet $\text{Dir}(\bar{\beta})$. À l'inverse, le critère forward induit un mélange arithmétique, en général multi-modal.

3 Dirichlet Prior Networks

On peut maintenant formaliser les Prior Networks et démontrer la thèse centrale de [2] : le critère d'entraînement adapté à ces modèles est la divergence de Kullback–Leibler inverse (reverse), et non la divergence directe (forward).

3.1 Définition et architecture

Définition 3.1. Un *Dirichlet Prior Network* est une application paramétrique

$$f_\theta : \mathcal{X} \longrightarrow (\mathbb{R}_+^*)^K, \quad x \mapsto \hat{\alpha}(x; \theta),$$

typiquement réalisée par un réseau de neurones produisant des logits $\hat{z}(x; \theta) \in \mathbb{R}^K$ suivis d'une activation strictement positive (par exemple $\hat{\alpha}_c = e^{\hat{z}_c}$). Elle paramétrise, pour chaque entrée x , une loi de Dirichlet sur le simplexe :

$$p(\pi \mid x; \theta) := \text{Dir}(\pi \mid \hat{\alpha}(x; \theta)).$$

Au lieu de prédire un point du simplexe (une unique loi catégorielle sur les classes), le réseau prédit une *loi sur le simplexe*, ce qui lui permet d'émuler un ensemble de modèles en une seule passe avant, et de produire des mesures d'incertitude riches.

Proposition 3.2 (Distribution prédictive = softmax). *La distribution prédictive sur les classes d'un Prior Network est la moyenne de sa Dirichlet :*

$$P(y = \omega_c \mid x; \theta) = \mathbb{E}_{p(\pi \mid x; \theta)}[\pi_c] = \frac{\hat{\alpha}_c(x; \theta)}{\hat{\alpha}_0(x; \theta)}.$$

En particulier, avec l'activation $\hat{\alpha}_c = e^{\hat{z}_c}$, on retrouve $P(y = \omega_c \mid x; \theta) = \text{softmax}(\hat{z})_c$.

Démonstration. Conditionnellement à π , la classe suit une loi catégorielle de paramètre π , donc $P(y = \omega_c \mid \pi) = \pi_c$. En marginalisant sur π ,

$$P(y = \omega_c \mid x; \theta) = \mathbb{E}_{p(\pi|x;\theta)}[P(y = \omega_c \mid \pi)] = \mathbb{E}_{p(\pi|x;\theta)}[\pi_c],$$

et la Proposition 2.8 donne $\mathbb{E}[\pi_c] = \hat{\alpha}_c / \hat{\alpha}_0$. Avec $\hat{\alpha}_c = e^{\hat{z}_c}$, $\hat{\alpha}_c / \hat{\alpha}_0 = e^{\hat{z}_c} / \sum_k e^{\hat{z}_k}$.

Ainsi, au niveau de la prédiction ponctuelle, un Prior Network à activation exponentielle coïncide avec un classifieur softmax usuel ; l'information supplémentaire réside dans l'étalement de la loi, contrôlé par la précision $\hat{\alpha}_0$. $\square$

3.2 Le problème d'apprentissage

Idéalement, on disposerait pour chaque entrée des paramètres $\beta^{(i)}$ d'une Dirichlet cible, et l'on minimiserait directement $\text{KL}[\text{Dir}(\beta^{(i)}) \parallel p(\pi \mid x^{(i)}; \theta)]$. En pratique, on ne dispose que de l'étiquette de classe $y^{(i)} \in \{\omega_1, \dots, \omega_K\}$.

Pour un classifieur ordinaire, ce n'est pas un obstacle : l'entropie croisée induit en espérance la bonne loi conditionnelle empirique.

Proposition 3.3. *Soit $\hat{p}_{\text{tr}}$ la loi empirique sur $\mathcal{X} \times \{\omega_1, \dots, \omega_K\}$ et $\hat{P}_{\text{tr}}(y \mid x)$ la loi conditionnelle empirique. Pour un classifieur $P(y \mid x; \theta)$,*

$$\mathbb{E}_{\hat{p}_{\text{tr}}} \left[- \sum_{c=1}^K \mathbf{1}\{y = \omega_c\} \log P(\omega_c \mid x; \theta) \right] = \mathbb{E}_{\hat{p}_{\text{tr}}(x)} \left[\text{KL} \left[\hat{P}_{\text{tr}}(y \mid x) \parallel P(y \mid x; \theta) \right] \right] + \text{cst.}$$

Démonstration. On écrit l'espérance jointe comme $\mathbb{E}_{\hat{p}_{\text{tr}}(x)} \mathbb{E}_{\hat{P}_{\text{tr}}(y|x)}$ et on utilise $\mathbb{E}_{\hat{P}_{\text{tr}}(y|x)}[\mathbf{1}\{y = \omega_c\}] = \hat{P}_{\text{tr}}(\omega_c \mid x)$:

$$\mathbb{E}_{\hat{p}_{\text{tr}}} \left[- \sum_c \mathbf{1}\{y = \omega_c\} \log P(\omega_c \mid x; \theta) \right] = \mathbb{E}_{\hat{p}_{\text{tr}}(x)} \left[- \sum_c \hat{P}_{\text{tr}}(\omega_c \mid x) \log P(\omega_c \mid x; \theta) \right].$$

La somme intérieure est l'entropie croisée $H(\hat{P}_{\text{tr}}(\cdot \mid x), P(\cdot \mid x; \theta))$ (pour la mesure de comptage sur les classes). Par la Proposition 3.9, elle vaut $\text{KL}[\hat{P}_{\text{tr}}(\cdot \mid x) \parallel P(\cdot \mid x; \theta)] + H(\hat{P}_{\text{tr}}(\cdot \mid x))$, et le second terme ne dépend pas de θ . $\square$

Mais entraîner un modèle qui est une loi sur les lois prédictives à partir d'échantillons de la loi prédictive (les étiquettes) est plus délicat. La solution de [2] consiste à choisir des distributions de Dirichlets cibles par classe et à minimiser une divergence KL vers celles-ci.

3.3 Distributions cibles par classe

Définition 3.4. On fixe un hyperparamètre $\beta_{\text{in}} > 0$. Pour chaque classe c , le vecteur de concentration cible $\beta^{(c)} \in (\mathbb{R}_+^*)^K$ est défini par

$$\beta_k^{(c)} := \begin{cases} \beta_{\text{in}} + 1 & \text{si } k = c, \\ 1 & \text{si } k \neq c. \end{cases}$$

La loi $\text{Dir}(\beta^{(c)})$ est fortement piquée près du coin c du simplexe (pour β_{in} grand). Les concentrations devant être strictement positives, les composantes hors-classe sont fixées à 1 (Dirichlet uniforme dans ces directions) plutôt qu'à 0. Pour des entrées hors-distribution, on prend $\beta^{(c)} = (1, \dots, 1)$, la distribution de Dirichlet uniforme.

Dans toute la suite, on note $w_c(x) := \hat{P}_{\text{tr}}(y = \omega_c \mid x)$ la probabilité empirique de la classe c , de sorte que $w_c(x) \geq 0$ et $\sum_{c=1}^K w_c(x) = 1$.

3.4 Critère forward et cible induite

Définition 3.5. Le *critère forward* (KL directe) est

$$\mathcal{L}_{\text{KL}}(y, x, \theta) := \sum_{c=1}^K \mathbf{1}\{y = \omega_c\} \cdot \text{KL}[\text{Dir}(\beta^{(c)}) \| p(\pi \mid x; \theta)].$$

Théorème 3.6 (Le critère forward induit un mélange arithmétique). *En espérance sous la loi empirique,*

$$\mathbb{E}_{\hat{p}_{\text{tr}}}[\mathcal{L}_{\text{KL}}] = \mathbb{E}_{\hat{p}_{\text{tr}}(x)}[\text{KL}[\bar{q}(\cdot \mid x) \| p(\pi \mid x; \theta)]] + \text{cst}, \quad \bar{q}(\cdot \mid x) := \sum_{c=1}^K w_c(x) \text{Dir}(\beta^{(c)}),$$

où *cst* ne dépend pas de θ . La cible induite $\bar{q}$ est le mélange arithmétique des Dirichlets cibles.

Démonstration. En écrivant $\mathbb{E}_{\hat{p}_{\text{tr}}} = \mathbb{E}_{\hat{p}_{\text{tr}}(x)} \mathbb{E}_{\hat{p}_{\text{tr}}(y|x)}$ et $\mathbb{E}_{\hat{p}_{\text{tr}}(y|x)}[\mathbf{1}\{y = \omega_c\}] = w_c(x)$,

$$\mathbb{E}_{\hat{p}_{\text{tr}}}[\mathcal{L}_{\text{KL}}] = \mathbb{E}_{\hat{p}_{\text{tr}}(x)} \left[\sum_c w_c(x) \text{KL}[q_c \| q_\theta] \right],$$

où l'on a noté $q_c = \text{Dir}(\beta^{(c)})$ et $q_\theta = p(\pi \mid x; \theta)$ (densités par rapport à λ_Δ). On développe la somme intérieure :

$$\sum_c w_c \text{KL}[q_c \| q_\theta] = \sum_c w_c \int q_c \log q_c d\lambda_\Delta - \sum_c w_c \int q_c \log q_\theta d\lambda_\Delta.$$

En posant $\bar{q} = \sum_c w_c q_c$, le second terme se factorise : $\sum_c w_c \int q_c \log q_\theta = \int \bar{q} \log q_\theta$. D'où, par la Proposition 3.9 :

$$\sum_c w_c \text{KL}[q_c \| q_\theta] = - \int \bar{q} \log q_\theta d\lambda_\Delta - \sum_c w_c H(q_c) = \text{KL}[\bar{q} \| q_\theta] + H(\bar{q}) - \sum_c w_c H(q_c) =: \text{KL}[\bar{q} \| q_\theta] + \text{cst}(x).$$

Le terme $\text{cst}(x)$ dépend de x (via les w_c) mais pas de θ . En prenant l'espérance sur $\hat{p}_{\text{tr}}(x)$, on obtient le résultat. $\square$

3.5 Critère reverse et cible induite

Définition 3.7. Le *critère reverse* (KL inverse) est

$$\mathcal{L}_{\text{RKL}}(y, x, \theta) := \sum_{c=1}^K \mathbf{1}\{y = \omega_c\} \cdot \text{KL}[p(\pi \mid x; \theta) \| \text{Dir}(\beta^{(c)})].$$

Théorème 3.8 (Le critère reverse induit une unique distribution de Dirichlet). *En espérance sous la loi empirique,*

$$\mathbb{E}_{\hat{p}_{\text{tr}}}[\mathcal{L}_{\text{RKL}}] = \mathbb{E}_{\hat{p}_{\text{tr}}(x)}[\text{KL}[p(\pi \mid x; \theta) \| \text{Dir}(\bar{\beta}(x))]] + \text{cst}, \quad \bar{\beta}(x) := \sum_{c=1}^K w_c(x) \beta^{(c)},$$

où *cst* ne dépend pas de θ . La cible induite est une unique Dirichlet, unimodale.

Démonstration. Comme précédemment, $\mathbb{E}_{\hat{p}_{\text{tr}}}[\mathcal{L}_{\text{RKL}}] = \mathbb{E}_{\hat{p}_{\text{tr}}(x)}[\sum_c w_c \text{KL}[q_\theta \| q_c]]$. On développe :

$$\sum_c w_c \text{KL}[q_\theta \| q_c] = \int q_\theta \log q_\theta d\lambda_\Delta - \int q_\theta \sum_c w_c \log q_c d\lambda_\Delta.$$

Or $\sum_c w_c \log q_c = \log \prod_c q_c^{w_c}$. Par la Proposition 2.15 (le mélange géométrique de Dirichlets est une Dirichlet), $\prod_c q_c^{w_c} = Z \cdot p(\pi \mid \bar{\beta})$ avec $\bar{\beta} = \sum_c w_c \beta^{(c)}$ et Z une constante indépendante de π . Donc $\sum_c w_c \log q_c = \log Z + \log p(\pi \mid \bar{\beta})$, et

$$\sum_c w_c \text{KL}[q_\theta \| q_c] = \int q_\theta \log \frac{q_\theta}{p(\pi \mid \bar{\beta})} d\lambda_\Delta - \log Z \underbrace{\int q_\theta d\lambda_\Delta}_{=1} = \text{KL}[q_\theta \| \text{Dir}(\bar{\beta})] - \log Z.$$

La constante $\log Z$ dépend de x mais pas de θ . En prenant l'espérance sur $\hat{p}_{\text{tr}}(x)$, le résultat tombe. $\square$

3.6 Thèse de l'article

La classe de modèles est exactement l'ensemble des distributions de Dirichlet unimodales $\{\text{Dir}(\hat{\alpha}) : \hat{\alpha} \in (\mathbb{R}_+^*)^K\}$. Comparons les deux cibles induites à cette classe.

-La cible reverse est dans la classe de modèles. Par le Théorème 4.8, la cible induite est l'unique distribution de Dirichlet $\text{Dir}(\bar{\beta}(x))$ avec $\bar{\beta}(x) = \sum_c w_c(x) \beta^{(c)} \in (\mathbb{R}_+^*)^K$. C'est exactement une loi de la classe de modèles : il existe donc un paramètre $\hat{\alpha}(x; \theta) = \bar{\beta}(x)$ qui annule la divergence KL. Le modèle peut représenter la cible exactement.

-La cible forward est en général hors de la classe de modèles.

Proposition 3.9. *Soit $K = 2$, $\beta_{\text{in}} > 1$ et $w_1 = w_2 = \frac{1}{2}$ (incertitude aléatoire maximale). La cible forward $\bar{q} = \frac{1}{2}\text{Dir}(\beta^{(1)}) + \frac{1}{2}\text{Dir}(\beta^{(2)})$ est bimodale sur Δ_1° , et n'est donc pas une densité de Dirichlet.*

Démonstration. Paramétrons Δ_1° par $\pi = (t, 1 - t)$, $t \in]0, 1[$. Ici $\beta^{(1)} = (\beta_{\text{in}} + 1, 1)$ et $\beta^{(2)} = (1, \beta_{\text{in}} + 1)$, et par symétrie $B(\beta^{(1)}) = B(\beta^{(2)}) =: B_0$. Les densités valent $p(\pi \mid \beta^{(1)}) = B_0^{-1} t^{\beta_{\text{in}}}$ et $p(\pi \mid \beta^{(2)}) = B_0^{-1} (1 - t)^{\beta_{\text{in}}}$, donc

$$\bar{q}(t) = \frac{1}{2B_0} (t^{\beta_{\text{in}}} + (1 - t)^{\beta_{\text{in}}}).$$

Sa dérivée $\bar{q}'(t) \propto \beta_{\text{in}} t^{\beta_{\text{in}}-1} - (1 - t)^{\beta_{\text{in}}-1}$ ne s'annule qu'en $t = \frac{1}{2}$. Pour $\beta_{\text{in}} > 1$, $\bar{q}'$ est négative sur $]0, \frac{1}{2}[$ et positive sur $]\frac{1}{2}, 1[$: $t = \frac{1}{2}$ est un minimum local, et $\bar{q}$ croît vers chacune des deux extrémités. La fonction possède donc deux modes (aux deux coins) : elle est bimodale. Or une densité de Dirichlet en dimension 1 (densité Bêta $t^{a-1}(1 - t)^{b-1}$ avec $a, b \geq 1$) est log-concave, donc unimodale. Ainsi $\bar{q}$ n'est pas une densité de Dirichlet. $\square$

3.7 Conclusion

Le critère forward induit une cible en général extérieure à la classe des Dirichlets, et force le modèle vers une distribution de Dirichlet de basse précision « inversée » en régime d'incertitude aléatoire. Le critère reverse induit une cible toujours intérieure à la classe de modèles, dont le mode et la précision reflètent correctement la distribution empirique

des classes. En pratique, le critère reverse est conjointement optimisé sur des données du domaine $\mathcal{D}_{\text{tr}}$ et hors-domaine $\mathcal{D}_{\text{out}}$:

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{in}}^{\text{RKL}}(\theta; \mathcal{D}_{\text{tr}}, \beta_{\text{in}}) + \gamma \cdot \mathcal{L}_{\text{out}}^{\text{RKL}}(\theta; \mathcal{D}_{\text{out}}, \beta_{\text{out}}),$$

avec $\beta_{\text{out}} = 0$ (cible uniforme, $\beta^{(c)} = (1, \dots, 1)$) et $\gamma > 0$ le poids hors-domaine.

Un avantage supplémentaire du critère reverse est qu'à la frontière entre domaine et hors-domaine, les concentrations cibles sont correctement interpolées : la cible étant toujours l'unique Dirichlet $\text{Dir}(\bar{\beta})$ avec $\bar{\beta}$ arithmétiquement interpolé, le degré d'interpolation est piloté de façon transparente par γ . Ce mécanisme permet aussi de généraliser l'entraînement adverse (en utilisant des exemples adversariaux comme données hors-distribution).

4 ANNEXE : Objets et Théorèmes utilisés

4.1 Espace mesuré et intégrale de Lebesgue

Définition 4.1. Un *espace mesuré* est un triplet $(X, \mathcal{B}, \mu)$ où $(X, \mathcal{B})$ est un espace mesurable et $\mu : \mathcal{B} \rightarrow \mathbb{R}_+$ est une mesure, c'est-à-dire une application vérifiant $\mu(\emptyset) = 0$ et la σ -additivité :

$$\mu\left(\bigsqcup_{n \in \mathbb{N}} A_n\right) = \sum_{n=0}^{+\infty} \mu(A_n)$$

pour toute suite $(A_n)_{n \in \mathbb{N}}$ d'éléments de $\mathcal{B}$ deux à deux disjoints.

La mesure de Lebesgue sur $(\mathbb{R}^n, \mathcal{B}_{\mathbb{R}^n})$ est notée λ_n ; elle est l'unique mesure sur $\mathcal{B}_{\mathbb{R}^n}$ invariante par translation attribuant la valeur 1 au cube $[0, 1]^n$. On pose $\lambda := \lambda_1$.

Définition 4.2 (Intégrale de Lebesgue). Soit $(X, \mathcal{B}, \mu)$ un espace mesuré.

(i) Pour $e : X \rightarrow \mathbb{R}_+$ étagée positive ($e = \sum_{i=1}^n a_i \mathbf{1}_{A_i}$ avec $A_i \in \mathcal{B}$), on pose

$$\int e \, d\mu := \sum_{a \in e(X)} a \, \mu(e^{-1}(\{a\})) \in \mathbb{R}_+.$$

(ii) Pour $f \in \mathcal{M}_+(X)$ (fonction mesurable à valeurs dans $\mathbb{R}_+$), on définit

$$\int f \, d\mu := \sup \left\{ \int e \, d\mu : e \text{ étagée positive, } e \leq f \right\} \in \mathbb{R}_+.$$

(iii) Pour $f \in L^1(X, \mu)$ (i.e. f mesurable à valeurs complexes et $\int |f| \, d\mu < +\infty$), l'intégrale $\int f \, d\mu \in \mathbb{C}$ est définie par décomposition en parties réelle/imaginaire positive/négative.

Rappelons les théorèmes fondamentaux sur l'échange limite-intégrale que nous utiliserons dans ce chapitre.

Théorème 4.3 (Convergence monotone, Théorème 3.1.6 de [1]). *Soit $(f_n)_{n \in \mathbb{N}}$ une suite croissante de fonctions dans $\mathcal{M}_+(X)$. Alors*

$$\lim_{n \rightarrow \infty} \int f_n \, d\mu = \int \lim_{n \rightarrow \infty} f_n \, d\mu.$$

Théorème 4.4 (Convergence dominée, Théorème 3.3.8 de [1]). *Soit $(f_n)_{n \in \mathbb{N}}$ une suite dans $\mathcal{M}(X)$ convergeant simplement vers $f \in \mathcal{M}(X)$. On suppose qu'il existe $g \in L^1_+(X, \mu)$ telle que $|f_n| \leq g$ pour tout $n \in \mathbb{N}$. Alors $f, f_n \in L^1(X, \mu)$ et*

$$\lim_{n \rightarrow \infty} \int f_n d\mu = \int f d\mu.$$

Théorème 4.5 (Fubini–Tonelli, Théorème 5.2.5 de [1]). *Soient $(X_1, \mathcal{B}_1, \mu_1)$ et $(X_2, \mathcal{B}_2, \mu_2)$ deux espaces mesurés σ -finis. On note $\mu := \mu_1 \otimes \mu_2$ la mesure produit sur $\mathcal{B}_1 \otimes \mathcal{B}_2$.*

(i) (**Tonelli**) *Pour tout $f \in \mathcal{M}_+(X_1 \times X_2)$,*

$$\begin{aligned} \int_{X_1 \times X_2} f d\mu &= \int_{X_1} \left(\int_{X_2} f(x_1, x_2) d\mu_2(x_2) \right) d\mu_1(x_1) \\ &= \int_{X_2} \left(\int_{X_1} f(x_1, x_2) d\mu_1(x_1) \right) d\mu_2(x_2). \end{aligned}$$

(ii) (**Fubini**) *Si $f \in L^1(X_1 \times X_2, \mu)$, les mêmes égalités valent dans $\mathbb{C}$.*

Théorème 4.6 (Changement de variables dans $\mathbb{R}^n$, Théorème 5.3.15 de [1]). *Soit $\psi : U \rightarrow V$ un C^1 -difféomorphisme entre deux ouverts de $\mathbb{R}^n$. Pour tout $f \in \mathcal{M}_+(V)$,*

$$\int_V f d\lambda_n = \int_U (f \circ \psi) |J_\psi| d\lambda_n,$$

où $J_\psi = |\det D\psi|$ est le jacobien de ψ . *L'égalité vaut encore pour $f \in L^1(V, \lambda_n)$.*

Théorème 4.7. [Dérivation sous le signe intégrale, Théorème 4.2.1 de [1]] *Soit $F : I \rightarrow \mathbb{C}$, $t \mapsto \int f(\cdot, t) d\mu$ une intégrale à paramètre. Si pour μ -presque tout $x \in X$ la fonction $t \mapsto f(x, t)$ est C^1 sur I , et s'il existe $g \in L^1_+(X, \mu)$ telle que $|\partial_t f(\cdot, t)| \leq g$ pour tout $t \in I$, alors $F \in C^1(I)$ et*

$$F'(t) = \int \partial_t f(\cdot, t) d\mu.$$

Théorème 4.8 (Inégalité de Jensen). *Soit $(X, \mathcal{B}, \mu)$ un espace de probabilité et $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ une fonction convexe. Pour toute $f \in L^1(X, \mu)$ telle que $\varphi \circ f \in L^1(X, \mu)$,*

$$\varphi\left(\int f d\mu\right) \leq \int \varphi \circ f d\mu.$$

Si φ est strictement convexe, l'égalité a lieu si et seulement si f est constante μ -presque partout.

4.2 La mesure de Lebesgue sur $\mathbb{R}$ et les intégrales de référence

Proposition 4.9 (Intégrabilité des fonctions puissance, Proposition 3.2.11 de [1]). *Pour $\alpha \in \mathbb{R}$, la fonction $t \mapsto t^{\alpha-1}$ est dans $L^1(]0, +\infty[, \lambda)$ si et seulement si $\alpha > 0$.*

Plus précisément, pour $\alpha > 0$,

$$\int_0^{+\infty} t^{\alpha-1} e^{-t} d\lambda(t) =: \Gamma(\alpha) \in (0, +\infty).$$

Cette intégrale définit la fonction Gamma d'Euler.

4.3 Optimisation sous contraintes

Théorème 4.10 (Conditions de Karush–Kuhn–Tucker). Soit $U \subset \mathbb{R}^K$ un ouvert, $F : U \rightarrow \mathbb{R}$ et $g : U \rightarrow \mathbb{R}$ deux fonctions de classe $\mathcal{C}^1$. On considère le problème d’optimisation sous contrainte

$$\max_{\pi \in U} F(\pi) \quad \text{sous la contrainte} \quad g(\pi) = 0.$$

Si π^* est un maximum local et si $\nabla g(\pi^*) \neq 0$ (qualification de la contrainte), alors il existe $\lambda \in \mathbb{R}$ tel que

$$\nabla F(\pi^*) = \lambda \nabla g(\pi^*).$$

Le scalaire λ est appelé multiplicateur de Lagrange associé à la contrainte $g = 0$.

De plus, si F est strictement concave sur $\{g = 0\} \cap U$, alors tout point vérifiant cette condition est l’unique maximum global du problème.

Démonstration. L’existence de λ découle du théorème des fonctions implicites : sous la condition $\nabla g(\pi^*) \neq 0$, la contrainte $g = 0$ définit localement une sous-variété de dimension $K - 1$ au voisinage de π^* , et tout vecteur tangent v à cette sous-variété vérifie $\nabla g(\pi^*)^\top v = 0$. En π^* maximum local, la différentielle de F restreinte à cette sous-variété est nulle, soit $\nabla F(\pi^*)^\top v = 0$ pour tout v tel que $\nabla g(\pi^*)^\top v = 0$. Par le lemme d’annulation (si un vecteur est orthogonal à tout le noyau d’une forme linéaire non nulle, il est colinéaire à cette forme), on conclut $\nabla F(\pi^*) = \lambda \nabla g(\pi^*)$ pour un certain $\lambda \in \mathbb{R}$.

La suffisance sous stricte concavité est classique : un point critique d’une fonction strictement concave sur un convexe est son unique maximum global. $\square$

Références

- [1] C. Lévy, *Intégration 1 — Notes de cours*, L3S5 Licence de Mathématiques, INUC Champollion / Institut de Mathématiques de Toulouse, 11 mars 2026.
- [2] A. Malinin et M. Gales, *Reverse KL-Divergence Training of Prior Networks: Improved Uncertainty and Adversarial Robustness*, NeurIPS 2019.
- [3] X. Gourdon, *Les maths en tête — Analyse*, Ellipses, 2021.